

요약문

본 연구는 수면 상담용 RAG 기반 챗봇(RESTDAWN) 캡스톤 프로젝트에서 도출된 상담 품질 고도화 과제를 데이터 마이닝 관점의 LLM 도메인 파인튜닝 실험으로 구체화하였다. Base 모델(base_mistral7b)에 대해 (1) 수면 지식 설명형(Stage1), (2) 상담형(Stage2), (3) 통합 분포(Stage3)로 데이터를 단계화하여 파인튜닝을 수행하고, Stage3에서는 warmstart(이전 단계 체크포인트 기반)와 scratch(base에서 직접 학습) 전략을 비교하였다. 평가는 RAGAS를 제외하고 ROUGE/BLEU/BERTScore의 자동 지표와 LLM-judge(pairwise win-rate)를 사용하였다. 실험 결과, Stage1과 Stage2에서 fine-tuned 모델은 base 대비 모든 자동지표에서 개선되었고, LLM-judge에서도 fine-tuned 선호가 뚜렷하게 나타났다. Stage3에서는 두 전략 모두 base 대비 향상되었으며, warmstart와 scratch는 지표별로 상이한 강점을 보였다. 본 연구는 기존 성능/계측 중심 실험에서 미흡했던 생성 품질 검증을 보완하고, 향후 Retrieval/LLM 공동 최적화 및 안전성 평가로 확장 가능한 근거를 제시한다.

목 차

1. 서론	5
1.1 연구 배경	5
1.2 연구 목적	5
1.3 연구 기여	5
2. 문제 정의 및 접근 전략	5
2.1 문제 정의	5
2.2 접근 전략(단계적 파인튜닝)	6
3. 실험 설정	6
3.1 모델	6
3.2 평가 지표	6
3.3 LLM-judge(정성+준정량)	6
4. 실험 결과	7
4.1 Stage1: fine-tuned vs base	7
4.2 Stage2: fine-tuned vs base	8
4.3 Stage3: warmstart vs scratch vs base	10
4.4 LLM-judge: base vs FT winrate & Δ winrate	12

5. 분석 및 고찰	13
5.1 Stage별 성능 향상 패턴	13
5.2 자동지표 관점의 해석	13
5.3 Stage3에서 warmstart vs scratch의 해석	14
5.4 LLM-judge 결과의 의미	14
6. 결론 및 향후 과제	16
6.1 결론	16
6.2 한계	16
6.3 향후 과제	16

1. 서론

1.1 연구 배경

캡스톤 디자인 “레스트던(RESTDAWN) - 맞춤형 수면 솔루션”은 사용자의 수면 기록·수면 일지 등을 기반으로 AI 챗봇 상담을 제공하는 프로토타입 서비스로, Flutter 클라이언트-Spring Boot 백엔드-MySQL·Qdrant로 구성된 3계층 구조 위에 RAG 기반 수면 정보 질의응답 기능을 포함한다. 수면 문제는 현대사회에서 광범위하며, 많은 사용자가 전문 진료 대신 검색/조언 수준으로 해결을 시도한다는 점에서, 쉽게 접근 가능한 상담/교육형 AI의 실효성이 크다. 하지만 캡스톤 보고서에서도 언급되듯, 제한된 시간·자원에서 프로토타입을 구현하는 과정에서 데이터 규모의 한계, 정량 실험 설계의 확장 필요, 상담 품질/안전성 고도화 필요가 개선 포인트로 도출되었다. 또한 기존 빅데이터 프로젝트(병렬화/계측 중심)에서는 LLM/생성 품질을 고정해두고, 품질(정확도·faithfulness 등)에 대한 체계적 비교를 수행하지 못한 한계가 명시되어 있다.

1.2 연구 목적

본 데이터 마이닝 프로젝트의 목적은 다음과 같다.

1. 수면 상담 도메인 데이터로 LLM을 단계적으로 파인튜닝하여(Stage1→Stage2→Stage3), 생성 품질을 정량·정성(LLM-judge) 지표로 검증한다.
2. Stage3에서 warmstart(이전 단계 체크포인트 기반)와 scratch(베이스에서 바로 학습)를 비교하여, 커리큘럼/초기화 전략이 품질에 미치는 영향을 분석한다.
3. 본 보고서는 RAGAS 평가는 실험 결과에서 제외하고, 텍스트 생성 품질 지표(ROUGE/BLEU/BERTScore) 및 LLM-judge에 집중한다.

1.3 연구 기여

- 캡스톤에서 제기된 상담 품질 고도화 과제를, 도메인 파인튜닝 실험으로 구체화해 정량 근거를 제시한다.
- 기존 빅데이터 프로젝트에서 미흡했던 “생성 품질 측정”을 보완한다.
- warmstart vs scratch 비교를 통해, 향후 (Retrieval/LLM/동시) 파인튜닝 로드맵 수립에 실험적 근거를 제공한다.

2. 문제 정의 및 접근 전략

2.1 문제 정의

수면 상담 챗봇에서 사용자가 기대하는 출력은 그럴듯한 일반 조언이 아니라,

- 질문의 의도를 반영한 구체적이고 실행 가능한 안내
- 의료/상담 맥락에서의 모호함 최소화
- 불필요한 환각(근거 없는 단정)을 줄인 일관된 톤과 구조

이다. 캡스톤에서도 RAG와 시스템 프롬프트로 무분별한 조언을 줄이려 했으나, 특정 상황에

서 부적절/모호 응답을 완전히 제거하기 어렵다는 점을 개선 과제로 제시했다.

따라서 도메인 데이터 기반의 모델 파인튜닝은, RAG가 제공하는 근거 문맥과 결합될 때 응답의 형식/표현/상답 구조를 안정화하는 핵심 수단이 된다.

2.2 접근 전략(단계적 파인튜닝)

본 프로젝트는 데이터 성격을 3단계로 분리했다.

- Stage1 (Factual): 수면/건강 정보 설명형(QA, 지식 전달) 중심
- Stage2 (Counseling): 상담형(공감+질문+행동 제안 등) 중심
- Stage3 (Full): Stage1+Stage2 성격을 통합(혹은 더 넓은 분포)하여 실제 서비스 질의 분포에 가까운 형태로 확장

Stage3는 두 가지 학습 전략을 비교했다.

- Scratch: base 모델에서 Stage3 데이터로 직접 학습
- Warmstart: Stage2(상담형)까지 학습된 체크포인트에서 Stage3로 이어 학습

3. 실험 설정

3.1 모델

- Base: base_mistral7b
- Fine-tuned: Stage별 파인튜닝 체크포인트(Stage1/Stage2/Stage3 warmstart, Stage3 scratch)

학습 하이퍼파라미터/LoRA 여부 등 구현 세부는 본 보고서의 중심이 아니라, 단계적 파인튜닝 전략과 평가 결과에 초점을 둔다.

3.2 평가 지표(Automatic)

- ROUGE-1/2/L/Lsum (mean): 참조 답변과의 n-gram/서열 유사도
- Sentence BLEU(mean), Corpus BLEU: 문장/코퍼스 수준 정합성
- BERTScore F1(mean): 의미적 유사도(임베딩 기반)

3.3 LLM-judge(정성+준정량)

- Pairwise 비교로 base vs fine-tuned를 맞붙여 win-rate 산출
- 비교 수: 표에 제공된 설정(주로 n=50)
- Judge 모델: gpt-4o-mini(제공된 summary 기준)

LLM-judge는 자동지표와 상관성이 높을 때도 있지만, 상담 톤/구성/안전한 표현같은 정성 요소를 더 잘 반영할 수 있어 보완 지표로 사용한다.


4. 실험 결과

본 장에서는 Stage1/2/3 파인튜닝 성능을 base 모델과 비교하고, 자동지표 (ROUGE/BLEU/BERTScore) 및 LLM-judge pairwise winrate 결과를 제시한다. 본 프로젝트에서는 RAG 파이프라인의 검색 품질(RAGAS) 평가는 제외하고, 모델 자체 생성 품질 개선에 초점을 맞추었다.


4.1 Stage1: factual fine-tuning vs Stage1 base

Stage1(지식·사실 기반 응답)에서는 파인튜닝 모델이 base 대비 모든 지표에서 일관된 개선을 보였다.


- ROUGE-1: 0.3159 → 0.3939 (+0.0780)
- ROUGE-2: 0.0866 → 0.2041 (+0.1175)
- ROUGE-L: 0.1781 → 0.2697 (+0.0916)
- ROUGE-Lsum: 0.2109 → 0.2811 (+0.0703)
- sent-BLEU: 3.7745 → 12.2603 (+8.4857)
- corpus-BLEU: 3.9394 → 17.1373 (+13.1979)
- BERTScore(F1): 0.7860 → 0.8199 (+0.0338)




[그림 4.1.1] ROUGE-1/2/L/Lsum, BERTScore(F1)에서 base vs ft의 절대 점수 비교



[그림 4.1.2] sent-BLEU, corpus-BLEU에서 base vs ft의 절대 점수 비교



[그림 4.1.3] ROUGE/BERTScore의 개선폭




[그림 4.1.4] BLEU의 개선폭

Stage1에서 특히 BLEU 계열 개선폭이 큰 것은, 생성 결과가 정답 텍스트와의 n-gram 정합성이 크게 향상되었음을 시사한다. 동시에 ROUGE/BERTScore도 함께 상승하여, 단순 표면 일치뿐 아니라 의미 유사도 측면에서도 개선이 확인된다.


4.2 Stage2: counseling fine-tuning vs Stage2 base

Stage2(상담형 응답)에서도 파인튜닝 모델이 base 대비 전반적인 개선을 보였다. 상담 데이터는 답변 다양성이 크기 때문에 자동지표는 보수적으로 해석해야 하나, 지표 상승 방향이 일관적이라는 점이 의미가 있다.


- ROUGE-1: 0.2701 → 0.3161 (+0.0460)
- ROUGE-2: 0.0303 → 0.0800 (+0.0497)
- ROUGE-L: 0.1322 → 0.1855 (+0.0534)
- ROUGE-Lsum: 0.1658 → 0.1855 (+0.0197)
- sent-BLEU: 1.5308 → 5.7833 (+4.2525)
- corpus-BLEU: 1.2334 → 8.0054 (+6.7720)
- BERTScore(F1): 0.7609 → 0.7856 (+0.0247)




[그림 4.2.1] Stage2: fine-tuned vs base (ROUGE/BERTScore)



[그림 4.2.2] Stage2: fine-tuned vs base (BLEU)



[그림 4.2.3] Stage2: Δ (fine-tuned - base) (ROUGE/BERTScore)



[그림 4.2.4] Stage2: Δ (fine-tuned - base) (BLEU)

Stage2의 개선은 상담 응답의 구조화(공감→상황 확인→행동 제안) 및 도메인 톤 안정화에 기여했을 가능성이 높다. 이는 다음 절의 LLM-judge 결과에서도 추가로 뒷받침된다.

4.3 Stage3: warmstart vs scratch vs base (3-way 비교)

Stage3는 통합 분포(stage3_full)에서 파인튜닝 전략을 두 가지로 비교하였다.

- scratch(Full FT): base 대비 ROUGE/BLEU 개선폭이 상대적으로 큼
- warmstart(이전 단계 체크포인트로 시작): ROUGE/BLEU 개선은 다소 작지만 BERTScore가 상대적으로 유리한 패턴


(1) Stage3 scratch(Full FT) vs base

- ROUGE-1: 0.2740 → 0.3041 (+0.0300)
- ROUGE-2: 0.0342 → 0.0962 (+0.0620)
- ROUGE-L: 0.1340 → 0.1840 (+0.0500)
- ROUGE-Lsum: 0.1687 → 0.1878 (+0.0191)
- sent-BLEU: 1.6157 → 5.7089 (+4.0932)
- corpus-BLEU: 1.4617 → 8.1795 (+6.7178)
- BERTScore(F1): 0.7634 → 0.7648 (+0.0014)


(2) Stage3 warmstart vs base

- ROUGE-1: 0.2740 → 0.2985 (+0.0244)
- ROUGE-2: 0.0342 → 0.0876 (+0.0534)
- ROUGE-L: 0.1340 → 0.1766 (+0.0426)
- ROUGE-Lsum: 0.1687 → 0.1825 (+0.0137)
- sent-BLEU: 1.6157 → 5.1164 (+3.5007)
- corpus-BLEU: 1.4617 → 7.5495 (+6.0878)


- BERTScore(F1): 0.7634 → 0.7664 (+0.0030)




[그림 4.3.1] Stage3: base vs warmstart vs scratch (ROUGE/BERTScore)



[그림 4.3.2] Stage3: Δ vs base (warmstart, scratch) (ROUGE/BERTScore)



[그림 4.3.3] Stage3: base vs warmstart vs scratch (BLEU)




[그림 4.3.4] Stage3: base vs warmstart vs scratch (BLEU)

Stage3 자동지표만 보면 scratch가 ROUGE/BLEU 향상이 크고, warmstart는 상대적으로 작은 향상을 보이지만 BERTScore가 더 유리한 경향을 보인다. 즉, 표면 정합성(ROUGE/BLEU)과 의미적 안정성(BERTScore) 사이의 트레이드오프 가능성이 제기된다.


4.4 LLM-judge: base vs FT winrate 및 Δwinrate

LLM-judge pairwise 평가(모델: gpt-4o-mini)에서는 Stage가 진행될수록 fine-tuned 선호가 강해졌다. 특히 Stage3에서 winrate가 크게 상승한다.

- Stage1 (50 judged, invalid 1): FT 0.66 vs Base 0.32 → $\Delta +0.34$
- Stage2 (50 judged): FT 0.74 vs Base 0.26 → $\Delta +0.48$
- Stage3 warmstart (50 judged): FT 0.90 vs Base 0.10 → $\Delta +0.80$
- Stage3 scratch/full (50 judged): FT 0.92 vs Base 0.08 → $\Delta +0.84$



[그림 4.4.1] LLM-judge Δ winrate (FT - base)




[그림 4.4.2] LLM-judge Δ winrate (FT - base)

자동지표 개선뿐 아니라, LLM-judge 기반 선호도에서도 파인튜닝의 효과가 명확히 관찰되었다. 이는 상담형 응답에서 중요한 일관성·자연스러움·사용자 친화적 설명 같은 정성 요소가 개선되었을 가능성을 시사한다.

5. 실험 결과

5.1 Stage별 성능 향상 패턴: 도메인 적합성의 누적 효과

Stage1→Stage2→Stage3로 갈수록(데이터 분포가 상담·통합으로 확장될수록) LLM-judge winrate가 크게 상승했다. 이는 단일 태스크 성능 향상보다, 도메인/대화 스타일 학습의 누적 효과가 사람(또는 judge) 관점의 선호에 직접적으로 기여했음을 의미한다.




[그림 5.1] LLM-judge - Base vs Fine-tuned Winrate 비교

특히 Stage3에서 winrate가 0.90~0.92로 급등한 것은, 통합 분포 학습이 상담 응답의 품질 기준(맥락 유지, 과도한 단정 감소, 적절한 행동 제안 등)에 더 잘 부합했음을 뒷받침한다.

5.2 자동지표 관점의 해석: ROUGE/BLEU 개선이 의미하는 것과 한계

Stage1과 Stage2에서 BLEU/ROUGE가 큰 폭으로 상승했다. 이는 참조 응답과의 표현적 정합성이 개선되었음을 의미한다.



[그림 5.2] Stage1 - Base vs Fine-tuned 자동지표 비교


다만 상담형 데이터는 정답이 하나로 수렴하지 않기 때문에, BLEU/ROUGE만으로 상담 품질을 완전히 설명하기 어렵다. 따라서 Stage2/3에서는 자동지표를 보조적 신호로 활용하고, LLM-judge 또는 사용자 평가 기반 품질 기준(공감/안전/행동계획 제안)을 함께 보는 것이 합리적이다.

5.3 Warmstart vs Scratch: 목표에 따른 선택 (정합성 vs 안정성)

Stage3에서 scratch는 ROUGE/BLEU 계열 개선폭이 더 컸고, warmstart는 BERTScore 개선

이 상대적으로 유리한 양상을 보였다. 이는 다음과 같은 가설로 해석할 수 있다.

- Scratch: 새로운 분포(stage3_full)에 대해 빠르게 정답 근접한 표현을 학습하여 ROUGE/BLEU 상승
- Warmstart: 이전 단계에서 형성된 상담 톤/구조를 유지하며 의미 안정성을 확보 (BERTScore 이점)




[그림 5.3] Stage3: base vs warmstart vs scratch (ROUGE/BERTScore)

실제 서비스 관점에서 안전하고 일관된 상담을 최우선으로 두면 warmstart가 유리할 수 있고, 정답 텍스트 근접(정보 설명 정확성)을 더 중시하면 scratch가 유리할 수 있다. 본 프로젝트에서는 LLM-judge winrate가 scratch(0.92)와 warmstart(0.90) 모두 매우 높아, 두 전략 모두 실용적 선택지임을 확인하였다.

5.4 LLM-judge 결과의 의미: 사용자 체감 품질과의 연결 가능성

LLM-judge는 정답 문자열 일치보다 문맥 유지, 응답의 구조적 완성도, 과도한 단정/환각 감소, 상담 톤 같은 요소를 반영할 가능성이 크다. Stage3에서 winrate가 크게 상승한 것은, 파인튜닝이 사용자 체감 품질에 가까운 축에서 효과를 냈다는 간접 근거다.



[그림 5.4 (재인용)] LLM-judge - ΔWinrate(FT-Base) 비교

다만 judge 자체의 편향(모델 성향, 프롬프트, 기준의 일관성)과 데이터 샘플 수(주로 50쌍)의 한계가 있으므로, 추후에는 사용자 평가(설문/선호/재사용률) 또는 다중 judge(서로 다른 모델)로 신뢰도를 보강할 필요가 있다.

6. 결론 및 향후 과제

6.1 결론

- Stage1/Stage2/Stage3 모든 단계에서 fine-tuned 모델이 base 대비 자동지표에서 개선되었다.
- Stage3에서는 warmstart와 scratch가 서로 다른 강점(의미 안정성 vs 텍스트 근접성)을 보일 가능성이 있으며, 목적(상담 안전성/사용자 만족) 기준으로 선택해야 한다.
- LLM-judge는 Stage가 진행될수록 fine-tuned 선호가 커지는 결과를 보여, 도메인 파인튜닝이 상담 품질에 실질적 도움이 된다는 정성 근거를 제공한다.

6.2 한계

- 자동지표는 상담형 답변에서 정답 다양성을 충분히 반영하지 못한다(BLEU/ROUGE).
- LLM-judge는 평가 모델 편향 및 프롬프트 설계에 영향을 받을 수 있다.
- 실제 서비스에서 중요한 안전성(위험 응답 탐지), 사용자 행동 변화 효과(수면 습관 개선) 등은 본 프로젝트에서 직접 측정하지 않았다.

6.3 향후 과제

빅데이터 프로젝트의 로드맵에서는 RAG 파인튜닝을 Retrieval/LLM/동시 3방향으로 나누고, 이후 Retrieval 파인튜닝에 집중하겠다고 정리했다. 이를 본 연구(LLM 파인튜닝 성과)와 연결하면, 다음의 통합 발전이 가능하다.

1. Retrieval 품질·지연 동시 최적화 + 생성 품질 공동 평가
 - 기존에 구축한 계층 파이프라인으로 latency를 보면서, 품질지표를 함께 넣어 Pareto frontier 탐색(빅데이터 보고서의 방향성)
2. 상담 안전성 가드레일 강화
 - 캡스톤 개선 희망사항에서 제시된 위험 응답 탐지/키워드 필터/추가 확인 질문 등 로직을 결합
3. 실사용자 파일럿 및 행동 변화 기반 평가
 - 제한된 데이터 평가를 넘어, 실제 사용자 집단을 대상으로 수면 점수 변화/만족도 측정 실험 설계
4. Warmstart 정책의 정교화
 - (Stage2→Stage3) 단일 warmstart뿐 아니라, 혼합 데이터 커리큘럼, 비율 스케줄링 등으로 분포 충격을 완화하는 전략 비교